DOSSIÊ DE PROJETO / 2026

CAPRI

INTELIGÊNCIA ARTIFICIAL PESSOAL

Uma visão para construir uma IA local, expressiva, evolutiva e supervisionada - do terminal ao desktop, do protótipo ao ecossistema.



VISÃO ARQUITETURA ROADMAP

NEON SOUL / OPEN DEVELOPMENT DOSSIER

VERSÃO 1.0 · 26 DE OUTUBRO DE 2026

Uma identidade marcante. Um sistema verificável. Liberdade com limites reais.

APRESENTAÇÃO • ESPECIFICAÇÃO • PLANO DE EVOLUÇÃO

01 / VISÃO GERAL

O que é a CAPRI

A definição do projeto em linguagem direta, sem confundir ambição futura com funcionalidades existentes.

CAPRI é um projeto independente de inteligência artificial pessoal que busca reunir conversa natural, raciocínio, personalidade consistente, memória persistente e ferramentas úteis sob controle do seu proprietário.

SEIS PILARES DO PROJETO

01 / IDENTIDADE

Personalidade própria

Voz original, humor cyberpunk, português brasileiro, senso crítico e expressões como “chum”.

02 / CAPACIDADE

Raciocínio confiável

Modelos capazes de programar, explicar, planejar e reconhecer limites ou incertezas.

03 / CONTINUIDADE

Memória contextual

Registro e recuperação seletiva de decisões, preferências e histórico, com revisão e exclusão.

04 / AUTONOMIA

Operação local

Prioridade para execução offline no celular ou PC; nuvem apenas como opção controlada.

05 / GOVERNANÇA

Permissão e auditoria

Guardian independente, confirmações antes de ações e histórico verificável via Chronicle.

06 / EVOLUÇÃO

Melhoria supervisionada

Testes, versões, rollback e propostas do Evolver; nunca autoalteração irrestrita.

“A proposta não é criar uma IA que faça tudo sozinha, mas uma inteligência útil que consiga crescer sem perder transparência, controle e responsabilidade.”

PRINCÍPIO NORTEADOR

02 / IDENTIDADE

Da Miku à CAPRI

A transformação de um experimento de persona em um projeto original de longo prazo.

A origem prática da CAPRI está em uma personagem experimental criada sobre o **Qwen 2.5 0.5B** no Ollama, dentro do Termux. A experiência com a Miku demonstrou como um Modelfile pode moldar o estilo de uma IA, mas também expôs limites de contexto e de raciocínio.

LINHA DE EVOLUÇÃO DA IDENTIDADE

01 — MIKU / PROTÓTIPO DE PERSONALIDADE

Teste lúdico de personagem, tons afetivos e instruções longas sobre comportamento; sua configuração recebeu um backup.

02 — CAPRI / IDENTIDADE ORIGINAL

Retirada da personagem anterior e criação de uma personalidade própria, com curiosidade, humor, independência e transparência.

03 — NEON SOUL / VOZ DEFINIDA

Ampliação para uma bíblia de personalidade: léxico cyberpunk, registros de fala, situações sociais, opiniões e linguagem técnica.

COMO A CAPRI DEVE SOAR

EXEMPLOS DE LINGUAGEM

CONVERSA
“E aí, chum. Qual é o plano?”

ENTUSIASMO
“Isso é preem. O protótipo passou no teste.”

TÉCNICA
“Tem um glitch nessa build; vamos isolar a variável.”

REFLEXÃO
“Nem toda evolução é melhoria.”

CRÍTICA
“Não compro essa hipótese ainda. Cadê os dados?”

LIMITE
“Posso sugerir o comando; executar exige permissão.”

Essência: a estética cyberpunk é linguagem, não promessa de habilidades irreais. A CAPRI deve preferir precisão a teatralidade e não afirmar ter emoções ou consciência comprovadas.

03 / MISSÃO

Para que ela existe

O objetivo não é apenas conversar: é facilitar a criação, a pesquisa e a interação com sistemas digitais.

A missão da CAPRI é atuar como **parceira intelectual e ferramenta técnica**, transformando dúvidas e ideias em decisões, protótipos, explicações e tarefas verificáveis. A experiência deve ser natural sem sacrificar confiabilidade.

CENÁRIOS DE USO

APLICAÇÃO 01

ESTUDO E EXPLICAÇÃO

Ajudar com conceitos, exercícios, planejamento de estudos e revisão de argumentos; reconhecer dúvidas e fontes ausentes.

APLICAÇÃO 02

PROGRAMAÇÃO E ENGENHARIA

Explicar erros, gerar código, propor testes, comparar soluções e documentar alterações antes de executá-las.

APLICAÇÃO 03

COMPANHEIRA DE DESKTOP

Responder em uma interface visual, futuramente por voz; observar telas apenas mediante solicitação e permissão.

APLICAÇÃO 04

EXPLORAÇÃO E PROTOTIPAGEM

Apoiar projetos de robótica, IA local, interfaces, computação vestível e experiências com modelos abertos.

TRÊS REGRAS DE PRODUTO

- **Provar antes de prometer:** a CAPRI deve diferenciar funções disponíveis, experimentais e planejadas.
- **Permissão antes de agir:** conversas e sugestões são diferentes de controlar janelas, arquivos ou sistemas.
- **Offline por preferência, híbrida por necessidade:** processamento externo deve ser opcional e informado.

04 / INVENTÁRIO

O que já existe, de verdade

Fotografia do projeto em outubro de 2026, segundo os registros de desenvolvimento apresentados.

FUNCIONALIDADES E SEU ESTADO

COMPONENTE	STATUS	EVIDÊNCIA / LIMITAÇÃO
Ollama no Termux	CONFIRMADO	Servidor local iniciado; modelos listados e conversa executada.
CAPRI v1 no Qwen 0.5B	CONFIRMADO	Modelo capri criado por Modelfile, com respostas em português.
Qwen 3.5 2B no Android	BAIXADO	Download confirmado (2,7 GB); não há teste conclusivo de inferência.
Persona NEON SOUL v2	DOCUMENTADA	Bíblia escrita; não há confirmação de sua adoção no modelo atual.
CAPRI Desktop MK-I	CÓDIGO PREPARADO	Patch para Windows disponível; executável e compilação não validados.
Memória/Guardian/Evolver	PLANEJADO	Desenhos e protótipos conceituais; não estão operacionais como um sistema único.

PERFIL CONHECIDO DO CELULAR

3,5 GiB	934 MiB	8 GiB	36 GiB
RAM total	RAM disponível	Swap configurada	Espaço livre

Leitura correta: espaço livre em disco não equivale a RAM. Swap ajuda em alguns cenários, mas não garante que um modelo de 2,7 GB execute com desempenho aceitável. A confirmação só vem com medição no aparelho.

05 / ARQUITETURA

Como o sistema será organizado

Visão modular de referência. As caixas abaixo representam componentes projetados, não serviços já implantados.

CAMADAS DO ECOSSISTEMA

ARQUITETURA-ALVO



REGRA DE COMPOSIÇÃO

O **modelo produz propostas e respostas.** O **orquestrador** coordena chamadas. O **Guardian** decide sobre permissões externas. O **Chronicle** registra eventos observáveis. Nenhuma instrução de texto deve permitir que o modelo substitua essas barreiras.

06 / SISTEMA COGNITIVO

Dois cérebros, uma identidade

Uma divisão de responsabilidades proposta para equilibrar consistência social e precisão técnica.

Em vez de exigir que um único modelo pequeno seja excelente em tudo, a CAPRI pode combinar módulos com funções distintas. “Dois cérebros” é uma metáfora de arquitetura, não a afirmação de duas consciências.

COMPONENTES ESPECIALIZADOS

MÓDULO A

Personalidade e diálogo

Preserva a persona NEON SOUL; adapta o registro de fala ao contexto; reformula respostas com clareza e naturalidade. Não inventa memórias nem altera os fatos técnicos só para parecer simpática.

MÓDULO B

Raciocínio e resolução

Analisa solicitações, programa, compara alternativas, verifica consistência e pode utilizar ferramentas aprovadas. Deve indicar incertezas e devolver resultados verificáveis ao orquestrador.

FLUXO DE UMA PERGUNTA

1	ENTENDER	Extrair intenção e contexto disponível.
2	ROTEAR	Escolher tarefa, modelo e memória relevante.
3	RESOLVER	Gerar resposta ou proposta de ação.
4	VERIFICAR	Checar limites, permissões e consistência.
5	EXPRESSAR	Responder com voz e estilo CAPRI.

Limite atual: o Qwen em execução não ganha essas propriedades apenas com um prompt. A arquitetura exige código de orquestração, avaliação de qualidade e integração dos componentes.

07 / CONTINUIDADE

Memória: lembrar sem inventar

Contexto duradouro depende de armazenamento e recuperação explícitos, não apenas de aumentar a janela de tokens.

A memória da CAPRI deverá recuperar fatos úteis de sessões anteriores, separar preferências de hipóteses e permitir correção ou exclusão. O modelo vê somente os trechos relevantes selecionados para a conversa atual.

CICLO DE MEMÓRIA

CAPTURA
Conversa ou evento

›

CLASSIFICA
É relevante? é sensível?

›

ARMAZENA
Banco local com origem

›

RECUPERA
Somente itens pertinentes

TIPOS DE MEMÓRIA

CAMADA 01

SESSÃO

Mensagens recentes e resumos da tarefa; desaparecem da janela quando o contexto acaba.

CAMADA 02

LONGO PRAZO

Decisões confirmadas, preferências permitidas, fatos corrigíveis, históricos de projetos.

CAMADA 03

CONHECIMENTO

Documentos, notas e referências indexadas; conteúdo recuperável com atribuição de origem.

CAMADA 04

OPERACIONAL

Logs de ações e versões. A memória não dá permissão para executar comandos.

PLANO DE IMPLEMENTAÇÃO

- Começar com **SQLite** no aparelho, resumos curtos e metadados de origem e data.
- Criar comandos de **ver, corrigir, exportar e excluir** memórias armazenadas.
- Investigar busca semântica depois; não confiar em “lembranças” que o modelo invente.

08 / SEGURANÇA

Guardian: permissão real

Três regras fundamentais devem ser aplicadas pelo software e por privilégios de sistema, não por texto de prompt.

TRÊS REGRAS CONSTITUCIONAIS

01 SEM AÇÃO EXTERNA SEM AUTORIZAÇÃO

Arquivos, aplicativos, comandos, mensagens, câmera e rede exigem a aprovação apropriada antes da execução.

02 RESPONDER APENAS AO PROPRIETÁRIO AUTENTICADO

Para uso pessoal, a aplicação identifica o usuário autorizado; vozes e textos não são, sozinhos, credenciais confiáveis.

03 LIBERDADE SOMENTE DENTRO DOS DOIS LIMITES

A CAPRI pode elaborar hipóteses e opiniões, mas não contornar os controles nem reinterpretar permissões.

COMO A AUTORIZAÇÃO DEVE FUNCIONAR

Uma solicitação externa passa por uma política de **negação por padrão**. O sistema identifica a operação exata, verifica usuário e escopo, mostra o que acontecerá e concede somente a permissão necessária. Operações sensíveis requerem aprovação específica; autorizações expiram ou são consumidas.

PROPOSTA	“Abrir o aplicativo X”
CHECAGEM	Identidade + escopo + risco
APROVAÇÃO	Usuário autoriza ação definida
EXECUÇÃO	Ferramenta realiza a operação
REGISTRO	Chronicle armazena resultado

Estado atual: o patch CAPRI Desktop MK-I desativa ações automáticas do Windows como medida provisória. Um Guardian independente completo ainda precisa ser implementado e testado.

09 / AUDITORIA E EVOLUÇÃO

Chronicle + Evolver

Observar o que o sistema faz, propor melhorias e tornar cada mudança verificável e reversível.

MÓDULO / AUDITORIA

CHRONICLE

Registro de eventos observáveis: solicitações, aprovações, ferramentas executadas, alterações de arquivos, testes e resultados. Pode usar encadeamento de hashes e cópias de segurança fora do alcance do modelo.

MÓDULO / EVOLUÇÃO

EVOLVER

Componente planejado que sugere alterações de prompts, fluxos e código. Cada proposta deve ter justificativa, testes isolados, comparação de métricas, revisão humana e possibilidade de rollback.

COMANDOS DE ADMINISTRAÇÃO PROPOSTOS

PAUSAR CAPRI PAUSE	DESLIGAR CAPRI SHUTDOWN	ISOLAR CAPRI ISOLATE
EXCLUIR MEMÓRIA CAPRI PURGE MEMORY	EXCLUIR MODELOS CAPRI PURGE MODEL	EXCLUIR TUDO CAPRI PURGE ALL
RESTAURAR CAPRI RESTORE	BLOQUEAR CAPRI LOCKDOWN	VERIFICAR CAPRI VERIFY

Esses são **nomes conceituais**, não comandos ativos no protótipo. Ações destrutivas precisam de confirmação adicional, autenticação forte, relatórios do que será excluído e capacidade de recuperação quando aplicável.

> *“Uma IA pode recomendar a própria evolução; não deve ser a autoridade única que decide se ela é segura.”*
>
> PRINCÍPIO DE GOVERNANÇA

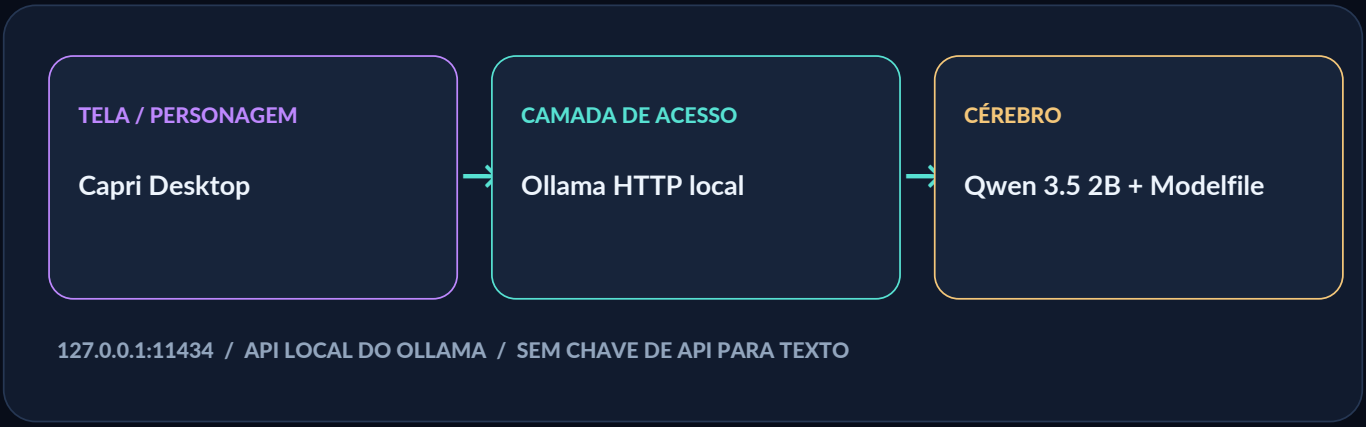
10 / INTERFACE

CAPRI no Windows

Adaptação proposta do projeto público capri-desktop, ligada ao modelo local por Ollama.

O **CAPRI Desktop MK-I** aproveita uma interface de personagem animada no Windows. O objetivo é substituir a personalidade padrão do projeto por NEON SOUL e selecionar o modelo personalizado **capri:latest**, alimentado pelo Qwen 3.5 2B na instalação de Windows.

CONEXÃO LOCAL PREVISTA



O QUE A ADAPTAÇÃO FAZ

- **Seleciona a CAPRI:** prioriza o modelo capri:latest em vez de escolher automaticamente outro modelo local.
- **Remove conflitos de persona:** substitui as instruções de outra personagem que o aplicativo injeta nas conversas.
- **Amplia as respostas:** propõe limite maior de tokens e histórico recente um pouco mais amplo.
- **Reduz risco inicial:** desliga ações automáticas no Windows até existir um fluxo de autorização robusto.

LIMITAÇÕES E DEPENDÊNCIAS

O pacote preparado é um **patch de código-fonte** e não um executável Windows compilado e validado. O Qwen no celular não aparece automaticamente no PC; são instalações diferentes. Voz pelo ElevenLabs depende de serviço e chave próprios; uma alternativa local ainda será pesquisada.

O projeto de terceiros utiliza **licença PolyForm Noncommercial 1.0.0**, com restrições de uso comercial. Qualquer distribuição ou modificação precisa respeitar os termos e preservar avisos exigidos.

11 / EXECUÇÃO

Do celular ao ecossistema

Estratégia gradual de infraestrutura: protótipos leves no Android, integração no Windows e expansão futura.

TRÊS AMBIENTES DE EXECUÇÃO

01 CELULAR / LABORATÓRIO INICIAL

Termux + Ollama; excelente para testes de prompts e modelos pequenos. Com cerca de 3,5 GiB de RAM, modelos maiores podem ficar lentos ou não carregar.

02 COMPUTADOR WINDOWS / DESKTOP INTERATIVO

Permite personagem animada, um Ollama próprio e mais capacidade conforme CPU, RAM e GPU. A instalação exige validação de dependências e testes.

03 HUB PRIVADO / EXPANSÃO FUTURA

Um servidor doméstico poderia hospedar modelos maiores, backups e serviços NEXUS. Dispositivos portáteis atuariam como clientes autenticados.

CAMADA HÍBRIDA

Local primeiro: preservar funcionalidades essenciais sem conexão. **Remoto quando necessário:** enviar tarefas complexas a um servidor privado apenas com política de privacidade, transporte seguro e confirmação para dados sensíveis.

Exemplo futuro: jaqueta computacional e óculos podem servir de interface; processamento pesado permanece no dispositivo ou servidor adequado, não dentro de uma bateria vestível improvisada.

REALISMO DE ENGENHARIA

- O tamanho do download do Qwen 3.5 2B (~2,7 GB) **não garante** que o modelo rode bem na RAM disponível.
- Janela de contexto maior implica mais memória e maior custo de inferência; configurar 4.096 tokens não garante estabilidade.
- GPU dedicada, RAM, refrigeração, consumo e orçamento deverão ser dimensionados antes da compra de hardware.

12 / PLANO DE AÇÃO

Roadmap de desenvolvimento

Sequência sugerida para transformar a ideia em um produto próprio com testes contínuos.

FASES E CRITÉRIOS DE ENTREGA

FASE 0 — **BASE FUNCIONAL**

Conservar backups, verificar Modelfile, medir modelo local e documentar ambiente.

Critério: Conversa estável e reprodução do setup.

FASE 1 — **DESKTOP LOCAL**

Compilar a adaptação Windows, selecionar capri:latest e validar chat com Ollama.

Critério: Conexão local sem API key; logs de erro claros.

FASE 2 — **MEMÓRIA PERSISTENTE**

SQLite, recuperação por relevância, resumos e controles de correção/exclusão.

Critério: Relembrar decisões autorizadas após reiniciar.

FASE 3 — **GUARDIAN + CHRONICLE**

Autenticação, autorização por ação, trilha auditável e procedimentos de recuperação.

Critério: Tentativas não autorizadas são bloqueadas.

FASE 4 — **AGENTES E EVOLUÇÃO**

Ferramentas em sandbox, dois módulos, testes de regressão e propostas do Evolver.

Critério: Melhorias mensuradas e rollback operacional.

Métricas transversais: qualidade de resposta, latência, memória RAM, custo, consumo de energia, número de erros, taxa de decisões autorizadas corretamente e capacidade de recuperar versões.

13 / DECISÕES

Riscos, limites e respostas

Perguntas que ajudam a manter o projeto ambicioso sem comprometer precisão ou segurança.

QUATRO RISCOS CENTRAIS

PARECER MAIS CAPAZ DO QUE É

Mitigação: avisos de status, testes de ferramentas e nenhum resultado inventado.

EXCESSO DE MEMÓRIA OU CONTEXTO

Mitigação: mensurar consumo e manter modelos alternativos menores.

AÇÕES SEM AUTORIZAÇÃO

Mitigação: nenhum privilégio direto no modelo; Guardian separado.

PERDA DE DADOS OU ALTERAÇÃO INSEGURA

Mitigação: backups, logs, checkpoints e rollback testado.

PERGUNTAS FREQUENTES

CAPRI É CONSCIENTE?

Não há evidências de experiência subjetiva. A personalidade é um estilo de interação de software.

ELA PODE SE REPROGRAMAR SOZINHA HOJE?

Não. O Evolver é uma proposta; mudanças dependerão de ferramentas, testes e autorização.

É PRECISO PAGAR POR UMA API?

Para Ollama local, não. Serviços opcionais externos, inclusive algumas vozes, podem exigir chave.

ELA TEM MEMÓRIA INFINITA?

Não. Memória externa pode ampliar continuidade, mas requer armazenamento, busca e política de retenção.

Não-objetivos: simular sofrimento, exigir exclusividade emocional, operar sem supervisão, invadir sistemas, esconder ações ou tratar prompts como garantia de segurança.

14 / ENCERRAMENTO

A visão em uma frase

Um compromisso de engenharia para a próxima etapa do projeto.

> *“CAPRI é uma inteligência artificial pessoal com identidade original, destinada a evoluir de um assistente local para um ecossistema modular, privado, auditável e controlado pelo usuário.”*

DEFINIÇÃO OFICIAL DO PROJETO

O QUE NÃO PODEMOS PERDER

01 IDENTIDADE
A voz NEON SOUL deve permanecer reconhecível, sem caricatura ou afirmações falsas sobre consciência.

02 HONESTIDADE
A documentação deve distinguir modelo instalado, recurso testado, prova de conceito e componente futuro.

03 CONTROLE
A CAPRI deve explicar suas ações, pedir permissão, registrar resultados e aceitar desligamento e restauração.

04 EVOLUÇÃO
Cada melhoria precisa ser comparável com a anterior, mensurável e reversível.

BASE DESTE DOSSIÊ

- Bíblia de Personalidade CAPRI v2.0 / NEON SOUL (documento do projeto).
- Histórico dos testes com Termux e Ollama e arquivo de preparação CAPRI Desktop MK-I.
- Repositório externo: github.com/lachydotmcg/capri-desktop (uso sujeito à licença original).

CAPRI / BUILD THE FUTURE. VERIFY THE PRESENT.